

# 正規分布

正田 備也

masada@rikkyo.ac.jp

# Contents

## 単変量正規分布

単変量正規分布の最尤推定


多変量正規分布

多変量正規分布の最尤推定

多変量正規分布の最尤推定の応用

# 正規分布 normal distribution

- ▶ ガウス分布 Gaussian distribution ととも呼ばれる
- ▶ 連続量をモデル化するときによく使われる
  - ▶ 下図は 2 変量正規分布の確率密度関数の例



# 単変量正規分布 univariate normal distribution

- ▶ 単変量正規分布は、 $(-\infty, \infty)$  上に定義される
- ▶ 単変量正規分布のパラメータは、平均  $\mu$  と標準偏差  $\sigma$ 
  - ▶ 平均  $\mu$ 、標準偏差  $\sigma$  の単変量正規分布を、以下  $\mathcal{N}(\mu, \sigma^2)$  と書く
  - ▶ 確率変数  $x$  が  $\mathcal{N}(\mu, \sigma^2)$  に従うことを、以下  $x \sim \mathcal{N}(\mu, \sigma^2)$  と書く
- ▶ 単変量正規分布  $x \sim \mathcal{N}(\mu, \sigma^2)$  の確率密度関数 pdf は

$$p(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \quad (1)$$

- ▶ 「;」 は、その右側にある  $\mu$  と  $\sigma$  が自由パラメータ（我々がその値を指定してはじめて分布が定まるパラメータ）であることを意味する

## 参考：ガウス積分


- ▶  $\frac{1}{\sqrt{2\pi\sigma^2}}$  って、何？
  - ▶  $-\infty$  から  $\infty$  までの範囲で積分すると 1 になるようにするには、この値を掛け算しておかないといけない、という意味
  - ▶ ひとことで言えば、規格化定数
- ▶ 逆に言えば、 $\int_{-\infty}^{\infty} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx = \sqrt{2\pi\sigma^2}$  が成り立つ、ということ
  - ▶ こういう積分を、ガウス積分と呼ぶ
  - ▶ ガウス積分の公式  $\int_{-\infty}^{\infty} e^{-a(x+b)^2} dx = \sqrt{\frac{\pi}{a}}$

## 密度関数についての注意事項（再）

$$p(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \quad (2)$$

- ▶ 式 (2) の  $x$  に特定の値を代入して得られる  $p(x; \mu, \sigma)$  の値は、確率としての意味を持たない
  - ▶ そもそも、密度関数の値は1を超えることがいくらかでもある
- ▶ 密度関数を特定の範囲で積分すると、確率とみなすことのできる値が得られる
  - ▶ 当然、全範囲で積分すると1になる（つまり  $\int_{-\infty}^{\infty} p(x; \mu, \sigma) dx = 1$ ）

# 単変量正規分布の密度関数の例



# 標準正規分布 standard normal distribution

- ▶ 平均が0で標準偏差が1の単変数正規分布  $\mathcal{N}(0, 1)$  のことを、標準正規分布と呼ぶ
- ▶ 標準正規分布に従う確率変数を  $x$  とする
- ▶ このとき、 $y = \sigma x + \mu$  は、平均が  $\mu$  で標準偏差  $\sigma$  の正規分布  $\mathcal{N}(\mu, \sigma^2)$  にしたがう
  - ▶ つまり、 $x \sim \mathcal{N}(0, 1)$  ならば  $\sigma x + \mu \sim \mathcal{N}(\mu, \sigma^2)$
  - ▶ 一般に、正規分布にしたがう確率変数のアフィン変換はまた、正規分布にしたがう



# 正規分布に独立にしたがう確率変数の和

- ▶ 確率変数  $x$  と  $y$  が、それぞれ独立に正規分布  $\mathcal{N}(\mu_x, \sigma_x^2)$  と  $\mathcal{N}(\mu_y, \sigma_y^2)$  にしたがうとする
- ▶ このとき、 $x + y$  も正規分布にしたがうことを、以下、示す
  - ▶  $\mathcal{N}(\mu_x, \sigma_x^2)$  と  $\mathcal{N}(\mu_y, \sigma_y^2)$  の密度関数を、それぞれ  $p(x; \mu_x, \sigma_x)$  と  $p(y; \mu_y, \sigma_y)$  と書く
  - ▶  $x$  と  $y$  は独立なので、同時分布の確率密度関数  $p(x, y)$  は  $p(x; \mu_x, \sigma_x)p(y; \mu_y, \sigma_y)$  と積で書ける
  - ▶  $z = x + y$  とおくと、 $y = z - x$
  - ▶  $y$  を  $z - x$  で置き換えて、 $x$  について積分する

cf. <https://faculty.math.illinois.edu/~r-ash/Stat/StatLec1-5.pdf> の Sec. 3.11

$$\begin{aligned}
& \int_{-\infty}^{\infty} p(x; \mu_x, \sigma_x) p(z - x; \mu_y, \sigma_y) dx \\
&= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma_x} \exp\left(-\frac{(x - \mu_x)^2}{2\sigma_x^2}\right) \frac{1}{\sqrt{2\pi}\sigma_y} \exp\left(-\frac{\{(z - x) - \mu_y\}^2}{2\sigma_y^2}\right) dx \\
&= \frac{1}{\sqrt{2\pi}\sigma_x} \frac{1}{\sqrt{2\pi}\sigma_y} \int_{-\infty}^{\infty} \exp\left(-\frac{(x - \mu_x)^2}{2\sigma_x^2} - \frac{\{(z - x) - \mu_y\}^2}{2\sigma_y^2}\right) dx
\end{aligned} \tag{3}$$

ここで、 $\exp()$  の中身を  $x$  について平方完成すると

$$\begin{aligned}
& -\frac{(x - \mu_x)^2}{2\sigma_x^2} - \frac{\{(z - x) - \mu_y\}^2}{2\sigma_y^2} = -\frac{\sigma_y^2(x - \mu_x)^2 + \sigma_x^2\{x - (z - \mu_y)\}^2}{2\sigma_x^2\sigma_y^2} \\
&= -\frac{(\sigma_x^2 + \sigma_y^2)x^2 - 2\{\sigma_y^2\mu_x + \sigma_x^2(z - \mu_y)\}x + \sigma_y^2\mu_x^2 + \sigma_x^2(z - \mu_y)^2}{2\sigma_x^2\sigma_y^2}
\end{aligned} \tag{4}$$

$$\begin{aligned}
& - \frac{(\sigma_x^2 + \sigma_y^2)x^2 - 2\{\sigma_y^2\mu_x + \sigma_x^2(z - \mu_y)\}x + \sigma_y^2\mu_x^2 + \sigma_x^2(z - \mu_y)^2}{2\sigma_x^2\sigma_y^2} \\
& = - \frac{\sigma_x^2 + \sigma_y^2}{2\sigma_x^2\sigma_y^2} \left\{ x^2 - 2 \frac{\sigma_y^2\mu_x + \sigma_x^2(z - \mu_y)}{\sigma_x^2 + \sigma_y^2} x \right\} - \frac{\sigma_y^2\mu_x^2 + \sigma_x^2(z - \mu_y)^2}{2\sigma_x^2\sigma_y^2} \\
& = - \frac{\sigma_x^2 + \sigma_y^2}{2\sigma_x^2\sigma_y^2} \left\{ x - \frac{\sigma_y^2\mu_x + \sigma_x^2(z - \mu_y)}{\sigma_x^2 + \sigma_y^2} \right\}^2 + \frac{\{\sigma_y^2\mu_x + \sigma_x^2(z - \mu_y)\}^2}{2\sigma_x^2\sigma_y^2(\sigma_x^2 + \sigma_y^2)} - \frac{\sigma_y^2\mu_x^2 + \sigma_x^2(z - \mu_y)^2}{2\sigma_x^2\sigma_y^2}
\end{aligned} \tag{5}$$

$x$  を含まない後半の 2 つの項に注目して  $z$  について平方完成すると

$$\begin{aligned}
& \frac{\{\sigma_y^2\mu_x + \sigma_x^2(z - \mu_y)\}^2}{2\sigma_x^2\sigma_y^2(\sigma_x^2 + \sigma_y^2)} - \frac{\sigma_y^2\mu_x^2 + \sigma_x^2(z - \mu_y)^2}{2\sigma_x^2\sigma_y^2} \\
& = \frac{\sigma_y^4\mu_x^2 + 2\sigma_x^2\sigma_y^2\mu_x(z - \mu_y) + \sigma_x^4(z - \mu_y)^2 - (\sigma_x^2 + \sigma_y^2)\{\sigma_y^2\mu_x^2 + \sigma_x^2(z - \mu_y)^2\}}{2\sigma_x^2\sigma_y^2(\sigma_x^2 + \sigma_y^2)} \\
& = \frac{2\mu_x(z - \mu_y) - \mu_x^2 - (z - \mu_y)^2}{2(\sigma_x^2 + \sigma_y^2)} = - \frac{1}{2(\sigma_x^2 + \sigma_y^2)} \{z - (\mu_x + \mu_y)\}^2
\end{aligned} \tag{6}$$

元に戻ると

$$\begin{aligned} & \frac{1}{\sqrt{2\pi}\sigma_x} \frac{1}{\sqrt{2\pi}\sigma_y} \int_{-\infty}^{\infty} \exp\left(-\frac{(x-\mu_x)^2}{2\sigma_x^2} - \frac{\{(z-x)-\mu_y\}^2}{2\sigma_y^2}\right) dx \\ &= \frac{1}{\sqrt{2\pi}\sigma_x} \frac{1}{\sqrt{2\pi}\sigma_y} \int_{-\infty}^{\infty} \exp\left[-\frac{\sigma_x^2 + \sigma_y^2}{2\sigma_x^2\sigma_y^2} \left\{x - \frac{\sigma_y^2\mu_x + \sigma_x^2(z-\mu_y)}{\sigma_x^2 + \sigma_y^2}\right\}^2 - \frac{\{z - (\mu_x + \mu_y)\}^2}{2(\sigma_x^2 + \sigma_y^2)}\right] dx \\ &= \frac{1}{\sqrt{2\pi}\sigma_x} \frac{1}{\sqrt{2\pi}\sigma_y} \exp\left[-\frac{\{z - (\mu_x + \mu_y)\}^2}{2(\sigma_x^2 + \sigma_y^2)}\right] \sqrt{\pi \frac{2\sigma_x^2\sigma_y^2}{\sigma_x^2 + \sigma_y^2}} \\ &= \frac{1}{\sqrt{2\pi}\sqrt{\sigma_x^2 + \sigma_y^2}} \exp\left[-\frac{\{z - (\mu_x + \mu_y)\}^2}{2(\sigma_x^2 + \sigma_y^2)}\right] \end{aligned} \tag{7}$$

ただし、途中で**ガウス積分**  $\int_{-\infty}^{\infty} e^{-a(x+b)^2} = \sqrt{\frac{\pi}{a}}$  を使った。

以上より、 $z \sim \mathcal{N}(\mu_x + \mu_y, \sigma_x^2 + \sigma_y^2)$  となることを示せた。

# 参考：変数変換

<http://nlp.dse.ibaraki.ac.jp/~shinnou/siryou/toukei-kentei/1-stat-var-trans.pdf>

## ▶ 1次元の場合

- ▶ 確率変数  $X$  の確率密度関数を  $f_X(x)$  とする
- ▶  $X$  を  $Y = g(X)$  と変数変換するとする
- ▶ 確率変数  $Y$  の密度関数  $f_Y(y)$  は  $f_Y(y) = f_X(x) \frac{dx}{dy}$  となる

## ▶ 2次元の場合

- ▶ 確率変数  $X$  と  $Y$  の同時密度関数を  $f_{X,Y}(x,y)$  とする
- ▶  $X$  と  $Y$  を  $(U,V) = (g_1(X,Y), g_2(X,Y))$  と変数変換するとする
- ▶  $U$  と  $V$  の同時密度関数は  $f_{U,V}(u,v) = f_{X,Y}(x,y) \|J\|$  となる
  - ▶  $J$  はヤコビアン  $J = \begin{bmatrix} \frac{\partial g_1^{-1}}{\partial u} & \frac{\partial g_1^{-1}}{\partial v} \\ \frac{\partial g_2^{-1}}{\partial u} & \frac{\partial g_2^{-1}}{\partial v} \end{bmatrix}$
  - ▶  $\|J\|$  はヤコビアン  $J$  の行列式の絶対値


( $U = X, V = X + Y$  の場合が、確率変数の和の場合に相当する) 13 / 43

# 確率変数の和がしたがる確率分布

- ▶ 正規分布の密度関数は、ラクダのコブのような形をしている
- ▶ ところで、たった今、異なる正規分布にしたがる独立な2つの確率変数の和が正規分布にしたがることを示した
- ▶ しかし、独立な2つの確率変数が、いずれもコブ状の密度関数をもつ分布にしたがるなら、それら確率変数の和がしたがる確率分布の密度関数には、2つのコブがあるのでは？
- ▶ …これはよくある勘違い。確率変数の足し算を考えると、密度関数の足し算を考えると、全く別のこと
- ▶ では、2つのコブがある分布はどのような場合に作られる？

# 混合分布

- ▶ 以下のようにして生成される観測データはどのような分布にしたがうか？
  - ▶ まずコインを投げる
  - ▶ 表が出たら  $\mathcal{N}(\mu_x, \sigma_x^2)$  から値を生成
  - ▶ 裏が出たら  $\mathcal{N}(\mu_y, \sigma_y^2)$  から値を生成
- ▶ このようにして生成される実数値がしたがう分布の密度関数には、コブが2つある
- ▶ このような分布を混合分布というが、詳細はまたいずれ



# 正規分布の再生性

- ▶ 再生性 reproductive property
  - ▶ 同じ分布だがパラメータが違うだけの分布に従う確率変数の和もまた、それら2つの分布とパラメータが違うだけの同じ分布に従うとき、この分布族は再生性を持つ、という。
- ▶  $M$  個の確率変数  $x_1, \dots, x_M$  が、それぞれ独立に正規分布  $\mathcal{N}(\mu_1, \sigma_1^2), \dots, \mathcal{N}(\mu_M, \sigma_M^2)$  にしたがうとする
- ▶ このとき、 $\sum_{m=1}^M a_m x_m$  は、以下の正規分布にしたがう

$$\mathcal{N}\left(\sum_{m=1}^M a_m \mu_m, \sum_{m=1}^M a_m^2 \sigma_m^2\right) \quad (8)$$



# Contents

単変量正規分布

単変量正規分布の最尤推定

多変量正規分布

多変量正規分布の最尤推定

多変量正規分布の最尤推定の応用

# 単変量正規分布に従う観測データの尤度

- ▶ 与えられている観測データを  $\mathcal{D} = \{x_1, \dots, x_N\}$  とする
  - ▶ 各  $x_i$  は、 $-\infty < x_i < \infty$  を満たす実数値とする
- ▶ 各  $x_i$  は同じ正規分布  $\mathcal{N}(\mu, \sigma)$  に独立にしたがうものとして、この観測データをモデル化することにする
- ▶ このときデータセット  $\mathcal{D}$  の尤度は、以下のような  $\mu$  と  $\sigma$  の関数になる

$$p(\mathcal{D}; \mu, \sigma) = \prod_{i=1}^N p(x_i; \mu, \sigma) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

(9)

# 単変量正規分布の最尤推定

- ▶ 観測データ  $\mathcal{D}$  の対数尤度は以下ようになる

$$\ln p(\mathcal{D}; \mu, \sigma) = -\frac{N}{2} \ln(2\pi\sigma^2) - \sum_{i=1}^N \frac{(x_i - \mu)^2}{2\sigma^2} \quad (10)$$

- ▶ この対数尤度を最大化する  $\mu$  と  $\sigma$  を、以下、求める

$$\frac{\partial \ln p(\mathcal{D}; \mu, \sigma)}{\partial \mu} = \sum_{i=1}^N \frac{x_i - \mu}{\sigma^2} \quad (11)$$

$$\frac{\partial \ln p(\mathcal{D}; \mu, \sigma)}{\partial \mu} = 0 \text{ より } \mu = \frac{\sum_i x_i}{N} = \bar{x}$$

$$\frac{\partial \ln p(\mathcal{D}; \mu, \sigma)}{\partial \sigma} = -\frac{N}{\sigma} + \sum_{i=1}^N \frac{(x_i - \mu)^2}{\sigma^3} \quad (12)$$

$$\frac{\partial \ln p(\mathcal{D}; \mu, \sigma)}{\partial \sigma} = 0 \text{ より } \sigma^2 = \frac{\sum_i (x_i - \mu)^2}{N} = \frac{\sum_i (x_i - \bar{x})^2}{N}$$

# Contents

単変量正規分布

単変量正規分布の最尤推定

多変量正規分布

多変量正規分布の最尤推定

多変量正規分布の最尤推定の応用

## 二変量正規分布 bivariate normal distribution

- ▶ パラメータ

- ▶ 平均ベクトル  $\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$

- ▶ 共分散行列  $\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{bmatrix}$  (ただし  $\boldsymbol{\Sigma}$  は正定値行列)

- ▶ 確率密度関数 (ただし  $|\boldsymbol{\Sigma}| \equiv \det \boldsymbol{\Sigma}$ )

$$p(\boldsymbol{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{\sqrt{(2\pi)^2 |\boldsymbol{\Sigma}|}} \exp \left\{ -\frac{(\boldsymbol{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\boldsymbol{x} - \boldsymbol{\mu})}{2} \right\} \quad (13)$$

# 多変量正規分布

## ▶ パラメータ

▶ 平均ベクトル  $\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_d \end{bmatrix}$

▶ 共分散行列  $\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1d} \\ \vdots & \ddots & \vdots \\ \sigma_{1d} & \cdots & \sigma_{dd} \end{bmatrix}$  (ただし  $\boldsymbol{\Sigma}$  は正定値行列)

## ▶ 確率密度関数 (ただし $|\boldsymbol{\Sigma}| \equiv \det \boldsymbol{\Sigma}$ )

$$p(\boldsymbol{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{\sqrt{(2\pi)^d |\boldsymbol{\Sigma}|}} \exp \left\{ -\frac{(\boldsymbol{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\boldsymbol{x} - \boldsymbol{\mu})}{2} \right\}$$

# 共分散行列 covariance matrix


- ▶ 二変量以上の場合、2つ以上成分をもつベクトルをモデル化
- ▶ ベクトルの第1成分、第2成分、等々について、各々単独での散らばり方は、当然考慮する
  - ▶ これが、共分散行列の対角成分、つまり分散に対応する
- ▶ これに加えて、第1成分と第2成分、第1成分と第3成分など、異なる成分間の関連も考慮する
  - ▶ これが、共分散行列の非対角成分、つまり共分散に対応する
- ▶ 共分散行列は分散共分散行列とも呼ばれる




# 共分散 covariance の直感的な意味

- ▶ 共分散は共分散行列の非対角成分に現れている値
- ▶ ゼロだと、対応する二つの成分は独立に分布
- ▶ 正の値だと、一方の成分が平均より大きいとき、他方の成分も平均より大きくなることが多い
- ▶ 負の値だと、一方の成分が平均より大きいとき、他方の成分は平均より小さくなることが多い

Positive  
covariance



Negative  
covariance



$$\mu = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$
$$\Sigma = \begin{bmatrix} 1 & -0.5 \\ -0.5 & 1.5 \end{bmatrix}$$




Figure: 二変量正規分布の密度関数の例

## 問題 4-1

- ▶  $\Sigma = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}$  の行列式  $\det \Sigma$  を求めよ。
- ▶  $\Sigma = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}$  の逆行列  $\Sigma^{-1}$  を求めよ。

## 二変量正規分布の別のパラメータ化(1/2)

- ▶ 同じ確率分布でも、パラメータ化 parameterization の方法が複数あることがある
- ▶ 二変量正規分布では、共分散行列を以下のようにパラメータ化することがある
  - ▶ 自由度は3で変わらないことに注意

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \quad (15)$$

## 二変量正規分布の別のパラメータ化(2/2)

- ▶ このパラメータ化のもとでは、 $\Sigma$  の行列式と逆行列は

$$\det \Sigma = \sigma_1^2 \sigma_2^2 (1 - \rho^2) \quad (16)$$

$$\Sigma^{-1} = \frac{1}{\det \Sigma} \begin{bmatrix} \sigma_2^2 & -\rho \sigma_1 \sigma_2 \\ -\rho \sigma_1 \sigma_2 & \sigma_1^2 \end{bmatrix} \quad (17)$$

# Contents

単変量正規分布

単変量正規分布の最尤推定

多変量正規分布

多変量正規分布の最尤推定

多変量正規分布の最尤推定の応用

# 多変量正規分布の最尤推定

- ▶ 観測データ  $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$  の各  $\mathbf{x}_i$  が独立に同じ正規分布  $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  にしたがうと仮定すると、 $\mathcal{D}$  の尤度は

$$\begin{aligned} p(\mathcal{D}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) &= \prod_{i=1}^N p(\mathbf{x}_i; \boldsymbol{\mu}, \boldsymbol{\Sigma}) \\ &= \prod_{i=1}^N \frac{1}{\sqrt{(2\pi)^d |\boldsymbol{\Sigma}|}} \exp \left( -\frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) \right) \quad (18) \end{aligned}$$

- ▶ 最尤推定によって各パラメータを推定（次スライドから）

cf. [The Matrix Cookbook](#)



## 行列やベクトルの偏微分の基本を再確認

$$\frac{\partial x_{kl}}{\partial x_{ij}} = \delta_{ik} \delta_{lj} \quad (19)$$

ただし、 $i = k$  ならば  $\delta_{ik} = 1$ 、そうでなければ  $\delta_{ik} = 0$

$$\left[ \frac{\partial \mathbf{x}}{\partial y} \right]_i = \frac{\partial x_i}{\partial y} \quad (20)$$

$$\left[ \frac{\partial x}{\partial \mathbf{y}} \right]_i = \frac{\partial x}{\partial y_i} \quad (21)$$

$$\left[ \frac{\partial \mathbf{x}}{\partial \mathbf{y}} \right]_{ij} = \frac{\partial x_i}{\partial y_j} \quad (22)$$

$$\begin{aligned}
\ln p(\mathcal{D}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) &= \sum_{i=1}^N \ln p(\mathbf{x}_i; \boldsymbol{\mu}, \boldsymbol{\Sigma}) \\
&= -\frac{Nd}{2} \ln(2\pi) - \frac{N}{2} \ln(|\boldsymbol{\Sigma}|) - \frac{1}{2} \sum_i (\mathbf{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu})
\end{aligned} \tag{23}$$

ここで、 $\bar{\mathbf{x}} = \frac{\sum_i \mathbf{x}_i}{N}$  として、

$$\sum_i (\mathbf{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) = \sum_i \mathbf{x}_i^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}_i - 2N\bar{\mathbf{x}}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu} + N\bar{\mathbf{x}}^\top \boldsymbol{\Sigma}^{-1} \bar{\mathbf{x}} \tag{24}$$

より、

$$\frac{\partial \ln p(\mathcal{D}; \boldsymbol{\mu}, \boldsymbol{\Sigma})}{\partial \boldsymbol{\mu}} = -N\boldsymbol{\Sigma}^{-1} \bar{\mathbf{x}} + N\boldsymbol{\Sigma}^{-1} \boldsymbol{\mu} \tag{25}$$

$$\therefore \boldsymbol{\mu} = \bar{\mathbf{x}} \tag{26}$$

$\frac{\partial \ln p(\mathcal{D}; \boldsymbol{\mu}, \boldsymbol{\Sigma})}{\partial \boldsymbol{\Sigma}}$  の計算は、[The Matrix Cookbook](#) を見ながらおこなう。

$$\frac{\partial}{\partial \boldsymbol{\Sigma}} \ln(|\boldsymbol{\Sigma}|) = \boldsymbol{\Sigma}^{-1} \quad (27)$$

$$\frac{\partial}{\partial \boldsymbol{\Sigma}} (\boldsymbol{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\boldsymbol{x}_i - \boldsymbol{\mu}) = -\boldsymbol{\Sigma}^{-1} (\boldsymbol{x}_i - \boldsymbol{\mu}) (\boldsymbol{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} \quad (28)$$

以上より、

$$\begin{aligned} \frac{\partial \ln p(\mathcal{D}; \boldsymbol{\mu}, \boldsymbol{\Sigma})}{\partial \boldsymbol{\Sigma}} &= -\frac{N}{2} \boldsymbol{\Sigma}^{-1} + \frac{1}{2} \boldsymbol{\Sigma}^{-1} \left( \sum_i (\boldsymbol{x}_i - \boldsymbol{\mu}) (\boldsymbol{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} \right) \boldsymbol{\Sigma}^{-1} \\ &= -\frac{1}{2} \boldsymbol{\Sigma}^{-1} \left\{ N - \left( \sum_i (\boldsymbol{x}_i - \boldsymbol{\mu}) (\boldsymbol{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} \right) \boldsymbol{\Sigma}^{-1} \right\} \end{aligned} \quad (29)$$

$$\therefore \boldsymbol{\Sigma} = \frac{1}{N} \sum_i (\boldsymbol{x}_i - \boldsymbol{\mu}) (\boldsymbol{x}_i - \boldsymbol{\mu})^\top \quad (30)$$

# Contents

単変量正規分布

単変量正規分布の最尤推定

多変量正規分布

多変量正規分布の最尤推定

多変量正規分布の最尤推定の応用

# 異常検知と 変化検知

Anomaly Detection  
and  
Change Detection

井手 剛  
杉山 将

Machine Learning Professional Series

## 気になるところから するする読める

- 異常や変化を実際に検知する現実世界の分析者向け。
- アルゴリズムとその活用例を広範囲に紹介。
- 考え方やモデルの「気持ち」を丁寧に解説。

**MLP** 機械学習  
プロフェッショナル  
シリーズ

講談社

# 異常検知への応用：ホテリングの $T^2$ 法の概要

- ▶ 異常値を含まない（あるいはほとんど含まない）データ集合を使って多変量正規分布のパラメータを最尤推定する
- ▶ 異常値かどうかを調べたいデータについて、最尤推定の結果を使って標本平均とのマハラノビス距離を求める
- ▶ マハラノビス距離が、あらかじめ計算しておいた閾値を超えたとき、警報を出す

# 観測データの異常度

- ▶ 最尤推定で求めた平均ベクトルを  $\hat{\mu}$ 、共分散行列を  $\hat{\Sigma}$  とする
- ▶ この推定値を使うと正規分布の密度関数は

$$p(\boldsymbol{x}; \hat{\mu}, \hat{\Sigma}) = \frac{1}{\sqrt{(2\pi)^d |\hat{\Sigma}|}} \exp \left\{ -\frac{1}{2} (\boldsymbol{x} - \hat{\mu})^\top \hat{\Sigma}^{-1} (\boldsymbol{x} - \hat{\mu}) \right\} \quad (31)$$

- ▶ そして、観測データ  $\boldsymbol{x}$  の異常度を  $-\ln p(\boldsymbol{x}; \hat{\mu}, \hat{\Sigma})$  と定義する
  - ▶ 直感的には、推定された平均ベクトル  $\hat{\mu}$  から遠いほど異常
  - ▶ ただし、ユークリッド距離を使っているのではない

# マハラノビス距離 Mahalanobis distance

- ▶ 異常度  $-\ln p(\boldsymbol{x}; \hat{\boldsymbol{\mu}}, \hat{\boldsymbol{\Sigma}})$  から定数部分を除いたものを、 $\boldsymbol{x}$  の  $\hat{\boldsymbol{\mu}}$  からのマハラノビス距離という
- ▶  $\boldsymbol{x}$  の  $\hat{\boldsymbol{\mu}}$  からのマハラノビス距離を  $\alpha(\boldsymbol{x})$  と書くことにすると

$$\alpha(\boldsymbol{x}) = (\boldsymbol{x} - \hat{\boldsymbol{\mu}})^{\top} \hat{\boldsymbol{\Sigma}}^{-1} (\boldsymbol{x} - \hat{\boldsymbol{\mu}}) \quad (32)$$

- ▶  $\alpha(\boldsymbol{x})$  が大きいほど、 $\boldsymbol{x}$  はより一層異常だとみなす
  - ▶  $\hat{\boldsymbol{\Sigma}}$  を使っているので、観測データのベクトルの成分間の関連も考慮した距離になっている




## ホテリングの $T^2$ 法

- ▶ 同じ  $d$  次元正規分布  $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  からの  $N$  個の独立なサンプルだと仮定された観測データに基づき、最尤推定により平均ベクトルを  $\hat{\boldsymbol{\mu}}$ 、共分散行列を  $\hat{\boldsymbol{\Sigma}}$  と、それぞれ推定したとする
- ▶ このとき、 $T^2 \equiv \frac{N-d}{(N+1)d}a(\mathbf{x})$  により定義される統計量  $T^2$  は、自由度  $(d, N-d)$  の F 分布にしたがう
- ▶  $N \gg d$  の場合は、 $a(\mathbf{x})$  は近似的に自由度  $d$  のカイ 2 乗分布にしたがう

# カイ2乗分布

- ▶ 独立に標準正規分布にしたがう  $k$  個の確率変数の二乗和がしたがう分布を、自由度  $k$  のカイ2乗分布とよぶ



# 閾値の決め方

- ▶ あらかじめ誤報率  $\alpha$  を決めておく
- ▶ 下の等式を満たすようにマハラノビス距離の閾値  $a_0$  を決める

$$1 - \alpha = \int_0^{a_0} \chi^2(x; d) dx \quad (33)$$

- ▶ ただし、 $\chi^2(x; d)$  は自由度  $d$  のカイ2乗分布の確率密度関数とする

